



BUDAPESTI MŰSZAKI ÉS GAZDASÁGTUDOMÁNYI EGYETEM
GAZDASÁG- ÉS TÁRSADALOMTUDOMÁNYI KAR
TESTNEVELÉSI KÖZPONT

VÁRI GERGŐ

TUDOMÁNYOS DIÁKKÖRI DOLGOZAT

Kosárlabda büntetődobás biomechanikai elemzése videó
alapján

Konzulensek:

Weisz-Tiba Klára Julianna
testnevelő tanár

Ágoston Dorottya
PhD hallgató

Budapest, 2026.

Tartalomjegyzék

1. Bevezetés és szakirodalmi áttekintés	1
1.1. A kosárlabda büntetődobás jelentősége és kihívásai	1
1.2. A kosárlabda dobások biomechanikai alapjai	2
1.2.1. Elengedési paraméterek	2
1.2.2. Kinetikai lánc és mozgásvariabilitás	3
1.3. Hagyományos és modern mozgáselemzési technológiák	3
1.3.1. Marker alapú mozgáskövető rendszerek	4
1.3.2. Marker nélküli pózbecslés és a MediaPipe	4
1.4. Kinematikai számítások és mesterséges intelligencia	6
1.5. Célkitűzések	7
2. Módszertan	8
2.1. Mérésben résztvevő személyek	8
2.2. Mérési eszközök és beállítás	8
2.3. Mérési protokoll	9
2.4. Adatfeldolgozás	10
2.5. Gépi tanulás	11
3. Eredmények	12
3.1. A szoftveres feldolgozás teljesítménye	12
3.2. A dobás fázisainak azonosítása	12
3.3. A klasszifikációs modell pontossága	13
4. Diskusszió és Összefoglalás	14
4.1. Az eredmények értékelése	14

4.2. Limitációk és továbbfejlesztési lehetőségek	15
4.3. Konklúzió	15
Irodalomjegyzék	16

1. fejezet

Bevezetés és szakirodalmi áttekintés

A kosárlabda az egyik legnépszerűbb sportág világszerte, amelyben a büntetődobás kritikus szerepet játszik a mérkőzések végkimenetelében. Mivel a büntetődobás egy zavartalan, rögzített távolságból végrehajtott statikus mozdulatsor, a sikeres végrehajtást szinte kizárólag a játékos technikája és biomechanikai mozgásmintája határozza meg. A magas szintű teljesítmény eléréséhez elengedhetetlen a mozgás optimalizálása, a dobás konzisztenciájának javítása és a hibák azonosítása.

Ebben a fejezetben a kosárlabda büntetődobások biomechanikai hátterének, a sportban alkalmazott mozgáselemző eljárásoknak, valamint a számítógépes látásmódon alapuló legmodernebb pózbecslési technikáknak (például OpenPose, YOLO, MediaPipe) az irodalmát tekintem át. Célom, hogy bemutassam, hogyan jutott el a sporttudomány a hagyományos, optikai markerekre épülő költséges vizsgálatoktól az okostelefonnal is felvehető, mesterséges intelligencia által támogatott elemzésekig. Bemutatom azokat a korábbi tanulmányokat, módszereket és eredményeket, amelyek lefektették az automatizált dobáselemzés alapjait, és amelyeket a jelen tudományos diákköri munkámban is alkalmazok.

1.1. A kosárlabda büntetődobás jelentősége és kihívásai

A kosárlabda egy rendkívül dinamikus sportág, amelyben a dobások pontossága és stabilitása döntő szerepet játszik a mérkőzések kimenetelében. Különleges helyet foglal el a játékelemek között a büntetődobás (free throw). Szemben a mezőnydobásokkal (jump shot, lay-up), a büntetődobás egy zárt láncú (closed-skill) motoros feladat, amelyet a játékosok mindig azonos távolságról (a büntetővonalától a gyűrű középpontjáig 4,225 méter), zavaró védők jelenléte nélkül, rögzített körülmények között hajtanak végre [1]. Ahogy arra Gómez és munkatársai [1] is rávilágítottak, ez az állandóság elméletileg tökéletes lehetőséget adna arra, hogy a játékosok rendkívül magas százalékkal értékesítsék

ezeket a dobásokat, azonban a gyakorlatban a fizikai fáradtság és a pszichológiai nyomás miatt a büntetődobások hatékonysága sokszor még a profik körében is ingadozó. Mivel egy szoros mérkőzés végeredménye gyakran néhány büntetőn múlik, a büntetődobás technikájának optimalizálása évtizedek óta kiemelt kutatási terület a sporttudományban [2].

Egy laikus számára a dobás egyszerűnek tűnhet: a labdát egy bizonyos ívben a kosár felé kell juttatni. A biomechanikai valóság azonban az, hogy a dobó játékosnak tucatnyi ízület és izomcsoport munkáját kell töredékmásodperc alatt tökéletesen összehangolnia – a boka és térd hajlításától kezdve a csípő, váll és könyök mozgásán át egészen a csukló végső "ostorcsapásáig" (wrist snap). Ha a dobás kinetikai láncolatában (kinetic chain) bármilyen aszimmetria vagy időzítési hiba lép fel, a mozgási energia átvitele nem lesz optimális, ami rontott dobást eredményez.

1.2. A kosárlabda dobások biomechanikai alapjai

A kosárlabda dobás kinetikai és kinematikai paramétereinek vizsgálata az 1980-as évektől kezdve intenzíven zajlik. A kutatások a legfontosabb tényezőket három alapvető elengedési paraméterre (release conditions) vezették vissza: az elengedési magasság (release height), az elengedési szög (release angle) és az elengedési sebesség (release velocity) [3].

1.2.1. Elengedési paraméterek

Az **elengedési magasság** azt határozza meg, hogy a talajtól milyen magasan hagyja el a labda a játékos kezét. A magasabb elengedési pont anatómiai okokból előnyös, mert csökkenti a gyűrűig megteendő utat, és lehetővé teszi, hogy a dobás röppályája kevésbé legyen meredek, így "nyitottabb" szögből érkezzon a gyűrűbe. Miller és Bartlett [4] korai tanulmányaiban leírták, hogy a profi játékosok tendenciózan nagyobb elengedési magasságot érnek el a kar maximális kinyújtásával (extenzió) és a törzs nyújtásával.

Az **elengedési szög** a labda vízszinteshez viszonyított szöge az elengedés pillanatában. Tran és Silverberg [3] matematikai modellezéssel kimutatták, hogy a férfi kosárlabdázók optimális elengedési szöge a játékos magasságától függően jellemzően 49° és 55° közé esik. Ha a szög túl lapos, a gyűrű "szája" oválisnak és szűknek hat a labda számára. Ha túl magas az ív, a dobás irányítása válik bizonytalanná, és kisebb eltérések is nagy hibát okoznak.

Az **elengedési sebesség** szorosan összefügg az elengedési szöggel. Ha a szöget növeljük, a labda célba juttatásához nagyobb kezdősebesség, és ezáltal nagyobb kifejtett

erő szükséges. A nagyobb erő kifejtése ugyanakkor a mozgáskoordináció romlásával járhat, ami növeli a hibázás valószínűségét [5]. Okazaki és Rodacki [5] vizsgálatai bebizonyították, hogy a dobótávolság növekedésével a játékosok kénytelenek csökkenteni a dobás szögét, hogy kompenzálják a megnövekedett erőigényt. A büntetődobás fix távolsága azonban lehetőséget ad az ideális állandó sebesség begyakorlására.

1.2.2. Kinetikai lánc és mozgásvariabilitás

A biomechanikai elemzések rámutattak a *kinetikai lánc* fontosságára a kosárlabda dobásban [6]. A dobás egy folyamatos láncreakció, amely az alsó végtagokban (boka, térd, csípő) keletkező erő generálásával indul, majd a törzsön keresztül jut el a vállhoz, a könyökhöz, a csuklóhoz, és végül az ujjakhoz. Bármilyen megakadás ebben a láncolatban kompenzációs mozdulatokat igényel a felső végtagoktól, ami a dobás pontosságának rovására megy.

További kiemelt kutatási terület a mozgás variabilitása, azaz annak mérése, hogy egy játékos mennyire képes ismételni ugyanazt a mozdulatot. Button és munkatársai [7] megvizsgálták a mozgásvariabilitást különböző tudásszintű játékosoknál a büntetődobás során. Kimutatták, hogy az elit játékosok könyök- és csuklóízületei sokkal stabilabb pályát írnak le. Később Mullineaux és Uhl [8] egy összehasonlító elemzésben rámutattak, hogy még az elit játékosok esetében is fellelhetők kinematikai eltérések a sikeres és a rontott dobások között. A rontott dobásoknál nagyobb szögvariabilitást figyeltek meg a térd és a váll ízületekben a dobás felkészülési szakaszában.

Bár vannak alapvető biomechanikai elvek, a dobástechnika erősen egyénfüggő [9, 10]. Az egyéni testarányok, izomzat és neurológiai adottságok miatt a játékosok saját optimális mozgásmintát (motor pattern) alakítanak ki. Rojas és munkatársai [11] szerint a játékosok a dobótávolság változása esetén is megőrzik egyéni dobásprofiljuk relatív időzítési arányait.

1.3. Hagyományos és modern mozgáselemzési technológiák

A fenti biomechanikai felismerések hosszú ideig a hagyományos, munkaigényes optikai mozgáskövető (motion capture) rendszereken alapultak. Ahhoz, hogy megértsük, milyen áttörést jelent a jelen dolgozatban alkalmazott mesterséges intelligencia, röviden át kell tekintenem a technológia fejlődését.

1.3.1. Marker alapú mozgáskövető rendszerek

Az elmúlt évtizedek sportbiomechanikai vizsgálatait az olyan optikai rendszerek uralták, mint a Vicon vagy az OptiTrack. Ezek a technológiák apró, fényvisszaverő passzív markereket ragasztanak a sportolók anatómiai pontjaira (ízületek, csontos kiemelkedések). Egy dedikált kamerarendszer rögzíti a markerek elmozdulását, amiből a szoftverek szubmilliméteres pontossággal kiszámolják a 3D kinematikai adatokat.

Bár a pontosságuk kimagasló, komoly korlátaik vannak [12]:

1. **A környezet kötöttsége:** Csak szigorúan kontrollált laboratóriumi körülmények között működnek, mert például a napfény hatása erős zavart okoz. A kamerák infravörös tartományban érzékelnek, és a napfény infravörös sugárzása zajt jelent a mérésben.
2. **Idő és erőforrás igény:** A markerek pontos felhelyezése és a kamerák felállítása akár 30 percet is igénybe vehet, amit meccsek során lehetetlen kivitelezni.
3. **Természetellenes mozgás:** A sportolók számára zavaró lehet a markerek sokasága, ami befolyásolja a mozgásmintát (ökológiai validitás probléma).
4. **Megbízhatóság (Reliability):** Az intra- és interrater megbízhatóság csökkenhet, mivel az anatómiai pontok meghatározása egyénenként eltérhet, és még azonos szakember is máshova helyezheti a markereket azonos emberen két különböző vizsgálat esetében.
5. **Mérési zaj:** A bőrmozgás miatti extra zaj, vagy egy-egy marker átmeneti kitakarása jelentős mérési hibákat okozhat.


1.3.2. Marker nélküli pózbecslés és a MediaPipe

Az utóbbi években a számítógépes látás és a mély konvolúciós neurális hálózatok (CNN) fejlődése elhozta a marker nélküli pózbecslés korszakát [13]. Egyszerű 2D videófelvételből a betanított algoritmusok képesek megbecsülni a kulcspontok (ízületek) pozícióit. Ez megszüntette a laboratóriumokhoz való kötöttséget: a sportolókat közvetlenül az edzőpályán lehet vizsgálni.

Az áttörést az OpenPose [14] keretrendszer 2017-es megjelenése jelentette, amely "bottom-up" (alulról építkező) módszert használt. Nakano és munkatársai [15] igazolták, hogy a marker nélküli becslés megbízható 2D kinematikai adatokat szolgáltat. A technológia finomodásával a "top-down" (felülről építkező) rendszerek kerültek előtérbe, mint a rendkívül gyors YOLO Pose.

A jelen kutatás szempontjából a legfontosabb mérföldkövet a Google által bemutatott MediaPipe BlazePose keretrendszer jelentette [16]. A MediaPipe nem csupán 2D, hanem pszeudo-3D mélységi koordinátákat is megbecsül egyetlen kamerakép alapján. A BlazePose architektúra egy detektor és egy nyomkövető hálózat kombinálásával működik: a folyamatos videófeldolgozásnál a drága detektor fázist átugorja, ami drasztikusan felgyorsítja a számításokat.

A MediaPipe 33 testpontot (kulcspontot) biztosít, köztük a kézfej finomabb referenciapontjait (csukló, hüvelykujj, kisujj, mutatóujj). Egy olyan finommotoros feladatnál, mint a büntetődobás, ahol az utolsó ujjbegy (release point) pozíciója döntő, ezek a kulcspontok kritikus fontosságúak. Koseki és kutatócsoportja [17] 2023-ban kifejezetten a MediaPipe-t használták kosárlabda dobáselemzésre, és megállapították, hogy a szűrt relatív ízületi szögek pontossága teljes mértékben alkalmas edzői elemző szoftverek megalkotására.



1.1. ábra. A MediaPipe által detektált 33 térbeli kulcspont rendszere.

A 1.1. ábrán látható, hogy a modell miként azonosítja be az emberi test kulcspontjait, amelyek alapján a kinematikai számítások elvégezhetők.

1.4. Kinematikai számítások és mesterséges intelligencia

A marker nélküli pózbecslők nyers adatait a mozgási elmosódás és ruhatakarás miatti zaj (jittering) miatt szűrni kell. A nemzetközi szakirodalom alapján [12] a biomechanikában a zéró fáziseltolású 4. rendű Butterworth aluláteresztő szűrők jelentik az iparági standardot, azonban a jelen dolgozatban a Savitzky-Golay szűrő alkalmazása mellett döntöttem, mivel ez a módszer kiválóan megőrzi az idősorok lokális maximumait és minimumait anélkül, hogy fáziseltolódást okozna, ami a dobás csúcspontjának (release) pontos meghatározásához elengedhetetlen.

A szűrt 3D vektorokból skaláris szorzat és trigonometrikus függvények segítségével kiszámíthatók a kulcsízületek – a boka, a térd, a csípő, a váll és a könyök – szögei [8]. Ezeknek a paramétereknek az időbeli alakulása alkotja a dobás **kinematikai idősorát**. Egy tipikus dobás idősorában egyértelműen azonosítható a dobás felkészülési szakasza (előkészítő guggolás, flexió), a felszálló szakasz (extenzió), az elengedés pillanata (release point), és a lecsengő, kísérő szakasz (follow-through). A kinetikai lánc (kinetic chain) vizsgálata a hagyományos kinematikában bevett szokás, azonban az egykamerás pózbecslési megoldások nem képesek erő- és nyomatékadatok kinyerésére, így jelen szoftverben a klasszikus értelemben vett kinetikai számítások helyett a kinematikai paraméterek fázisviszonyainak elemzésére szorítkozom.

Ahogy az adatmennyiség megnőtt, megnyílt a tér a gépi tanulási (Machine Learning, ML) algoritmusok előtt a sportban is. A kutatások egyre gyakrabban alkalmazzák a begyűjtött kinematikai idősorokat a dobás kimenetelének (találat vagy rontás) predikciójára [13]. Különböző osztályozó modellek – mint a Random Forest (Véletlen Erdő) vagy a Support Vector Machines (Támogató Vektor Gépek, SVM) – képesek megragadni azokat az apró, több dimenziós összefüggéseket a mozgásban, amelyeket az emberi szem nem észlel.

Ezek a rendszerek a jövőben proaktív eszközként működhetnek: egy okostelefonos alkalmazás valós időben figyelmeztetheti az edzőt a fáradásból adódó hibás dobástechnikára, még a teljesítményromlás vagy sérülés előtt. Jelen TDK dolgozat egy ilyen nyílt forráskódú, Python-alapú keretrendszert valósít meg, amely a MediaPipe pózbecslés és az arra épülő gépi tanulás alkalmazásával profi szintű kinematikai jelentéseket állít elő, hidat építve a számítógépes látás laboratóriumi tudománya és a gyakorlati sportedzés világa közé.

1.5. Célkitűzések

Jelen Tudományos Diákköri (TDK) munka célja egy olyan automatizált biomechanikai elemző szoftverrendszer kidolgozása, amely képes kosárlabda büntetődobások videós felvételeiből kinematikai adatokat kinyerni marker nélküli pózbecslés, valamint OptiTrack Mocap adatok felhasználásával. A kutatás során az alábbi célokat fogalmaztam meg:

- A dobás szempontjából kritikus paraméterek (boka-, térd-, csípő-, váll- és könyökszögek, extenzió, elengedési pont) folyamatos nyomon követése a mozgás során.
- Egy gépi tanulási (Machine Learning) klasszifikációs modell betanítása, amely kísérletet tesz a dobás kimenetelének (sikeres vagy sikertelen) előrejelzésére a kinyert adatok alapján.
- Annak vizsgálata, hogy a modern számítógépes látásmódon alapuló technológiák (YOLO és MediaPipe), valamint a klasszikus 3D marker alapú OptiTrack technológia miként integrálhatók egy automatizált, edzőket és játékosokat támogató sportanalitikai rendszerbe.

2. fejezet

Módszertan

2.1. Mérésben résztvevő személyek

A kutatás során 7 igazolt, versenyszerű kosárlabda múlttal rendelkező játékos (6 férfi, 1 nő) bevonásával végeztem az adatgyűjtést. Kizárólag sérülésmentes sportolókat vontam be a vizsgálatba. A mérésben résztvevő összes személy jobbkezes volt. A játékosok fizikai paramétereit és tapasztalati szintjét részletesen rögzítettem (lásd 2.1. táblázat). A teljes minta átlagéletkora $20,3 \pm 0,5$ év, átlagos testmagassága $185,8 \pm 7,0$ cm, míg átlagos testtömege $82,2 \pm 8,3$ kg volt. A résztvevők átlagosan $12,7 \pm 1,3$ év igazolt sportmúlttal rendelkeztek. Ezek a részletes fizikai és demográfiai adatok biztosították, hogy a gépi tanulási modell megfelelő és releváns variabilitású mintán kerüljön betanításra.

Nem	Életkor (év)	Testmagasság (cm)	Testtömeg (kg)	Tapasztalat (év)
Nő	-	-	-	-
Férfi	20	180	72	14
Férfi	19	179	87	14
Férfi	19	181	73	11
Férfi	20	186	80	14
Férfi	20	196	92	11
Férfi	19	193	89	12


2.1. táblázat. A mérésben résztvevő játékosok fizikai és demográfiai adatai. Valamennyi résztvevő jobbkezes volt.

2.2. Mérési eszközök és beállítás

A vizsgálat során a videóalapú pózbecslés mellett egy hagyományos, **OptiTrack Motive** 3D optikai mozgáskövető (mocap) rendszert is alkalmaztam referenciaként és a gépi tanulási modellek pontosságának növelése érdekében. A felvételeket párhuzamosan

két okostelefonnal (egy Android és egy iOS rendszerű készülékkel) is rögzítettem, egységesen 1080p (Full HD) felbontásban és 60 fps (képkocka/másodperc) rögzítési sebességgel. A monokuláris pozíbecslő rendszerek sajátossága, hogy nem igényelnek hagyományos 3D kamera kalibrációt, azonban a konzisztencia érdekében a kamerák dőlésszögét és magasságát minden felvételnél fixen tartottam.

A 2.1. ábra mutatja a mérés elrendezését. A játékos a szabványos büntetővonalon helyezkedett el, míg a kamerákat a játékostól balra, illetve jobbra, a gyűrűhöz kissé közelebb eső fix pozíciókban (oldalnézetből) állítottam fel, biztosítva, hogy a játékos teljes teste végig a látótérben maradjon.



2.1. ábra. A mérés sematikus elrendezése. A kamerák a játékoshoz képest oldalirányban, a gyűrű felé tolva helyezkedtek el.


2.3. Mérési protokoll

A videófelvételeket valós környezetben, szabványos kosárlabdapályán készítettem. A mérést megelőzően a játékosok egy rövid, sportágspecifikus bemelegítést végeztek, amely 3-8 szabadon választott bemelegítő büntetődobásból állt.

Ezt követően minden résztvevő 4 vagy 5 sorozatban hajtott végre 5-5 dobást. A dobások között 5-10 másodperc, míg a sorozatok között 1 perc pihenőidőt biztosítottam a fáradás minimalizálása érdekében. Néhány esetben egy-egy sorozatot technikai okok (pl. kitakarás) miatt újra kellett rögzítenem, illetve előfordult, hogy egyes játékosok kifejezett kérésére egy további (5.) sorozatot is felvettem. A felvételeken minden dobás kimenetelét (sikeres vagy sikertelen) manuálisan rögzítettem, amely elengedhetetlen feltétele volt a felügyelt gépi tanulásnak.

2.4. Adatfeldolgozás

A szoftveres adatfeldolgozás során nyertem ki a biomechanikai paramétereket a videókból. A folyamat lépéseit a 2.2. ábra szemlélteti.



2.2. ábra. A biomechanikai adatfeldolgozás automatizált szoftveres folyamatábrája.


A nyers videófelvételeket első lépésben automatikusan feldaraboltam, így önálló dobási klipek jöttek létre. A 3. lépésben (Pózbecslés) két különböző marker nélküli algoritmust integráltam a rendszerbe, amelyeket a precízebb elemzés érdekében kiegészítettem az OptiTrack rendszerből származó adatokkal:

- **YOLO (You Only Look Once):** GPU-ra optimalizált (TensorRT gyorsítással), ami 17 alapvető 2D kulcspontot azonosít.
- **MediaPipe:** 33 darab térbeli (3D) kulcspontot (köztük a kézfej pontjait) határoz meg. CPU-n fut, de párhuzamosítással kellően gyors, és a több referenciapont miatt részletesebb kinematikai elemzést tesz lehetővé.
- **OptiTrack Motive (Mocap):** Marker-alapú rendszer, amely fizikai markerek alapján milliméteres pontossággal követi a csontváz (skeleton) térbeli mozgását. Az adatok feldolgozásánál egy robusztus algoritmust alkalmaztam a különböző rögzítési azonosítók (pl. Skeleton1, Skeleton3) felismerésére. A rendszer minden dobásnál fixen ellenőrizte a legfontosabb 9 alapízület (pl. csukló, könyök, váll, térd) meglétét.

A felismert kulcspontok (illetve az OptiTrack markerek) alapján kiszámítottam a vizsgált ízületi szögeket (például a térdhajlítás és a könyök extenzió szöge). A dobás elengedési pontja (release point) a videó adatoknál a csukló Y-koordinátájának (függőleges) maximális értékéhez, az OptiTrack adatoknál pedig az ujjak markerének csúcspontjához lett rendelve. A Mocap adatok esetében a marker-kiesések kompenzálására az egyedi ujjmarkerek hiánya esetén az alapértelmezett kézfej (FIN) marker szolgált referenciaként, így garantálva a dobásonkénti konstans 527 bemeneti változót (feature).

A nyers idősorok zajszűréséhez egy Gauss-simítást (Gaussian filter) alkalmaztam. Fontos megjegyezni, hogy bár a biomechanikában gyakran használnak Butterworth

szűrőt, a jelenlegi szűrési eljárást azért választottam, mert ez a módszer kiválóan megőrzi a görbék lokális maximumait és minimumait anélkül, hogy fáziseltolódást okozna (vagyis az elengedés pillanatának időbeli helyzete nem tolódott el).



2.3. ábra. A feldolgozó rendszer által készített vizualizáció, amely valós időben mutatja az azonosított kulcspontokat és az aktuális hajlásszökeket.

A 2.3. ábra azt a valós idejű vizualizációt mutatja be, amelyet az adatok ellenőrzésére hoztam létre.

2.5. Gépi tanulás

A kinyert kinematikai adatokból komplex idősoros változókat (features) képeztem. A kulcsízületek (csukló, könyök, váll, csípő, térd, boka) függőleges elmozdulását és ízületi szögeit 30 egyenlő időlépésre (timestep) osztottam fel. Ezen felül olyan másodlagos paramétereket is meghatároztam, mint a csukló mozgástartomány, vagy a csukló sebessége az elengedés pillanatában.

A predikcióhoz együttes tanulási (ensemble) modelleket tanítottam be: a *Random Forest* (Véletlen Erdő) és a *Gradient Boosting* (Gradiens Emelés) algoritmusokat használtam. A modellek megbízhatóságának és általánosító képességének tesztelésére egy 5-szörös keresztvalidációs (StratifiedGroupKFold) módszert alkalmaztam. Ennek az eljárásnak a lényege, hogy egy játékos azonos dobásai (még ha két különböző kamerából is rögzítettük őket) soha nem kerülhettek egyszerre a modell tanítására és tesztelésére használt adatok közé. Ez a szigorú csoportosítás garantálta, hogy nem jött létre adatszivárgás (data leakage), így a validációs pontosság valós képet ad a rendszer teljesítményéről.

3. fejezet

Eredmények

3.1. A szoftveres feldolgozás teljesítménye

A kifejlesztett rendszeremmel sikeresen feldolgoztam az izolált videófelveteleket. A YOLO algoritmus grafikus kártyán futtatott, hardveresen gyorsított verziója kiemelkedően magas képkocka/másodperc (FPS) feldolgozási sebességet biztosított. A MediaPipe ezzel szemben a 33 darab, térbeli mélységinformációval is rendelkező kulcspont miatt lassabbnak bizonyult, de a párhuzamosítási technikák révén a feldolgozás átbocsátóképessége a gyakorlatban is használható szintre emelkedett. A Gauss-simításon alapuló zajszűrés mindkét technológia esetében sikeresen eliminálta a kulcspontok apró remegéseit (*jittering*).

A vizualizáció részeként legenerált áttetsző képernyőn (lásd 2.3. ábra) megfigyeltem, hogy az algoritmusok stabilan követik a játékosok mozgását, és az ebből számolt ízületi szögek (térd-, csípő- és könyökszög) megegyeznek a várt biomechanikai paraméterekkel.


3.2. A dobás fázisainak azonosítása

Az elengedési pont (release point) detektálására szolgáló algoritmus megbízhatóan azonosította a dobás tetőpontját. Az adatok alapján rögzítettem a sikeres és sikertelen dobások kinematikai görbéit. Megállapítottam, hogy a sikeres dobásoknál a könyök és térd időbeli extenziója szinkronban történik, és a görbék lefutása a játékosok több dobása esetén is szorosabb, konzisztensebb mintázatot mutat. Ezzel szemben a rontott kísérleteknél megnövekedett a mozgás variabilitása, és gyakran aszinkronitást figyeltem meg az alsó és felső végtagok mozgásláncában az elengedés pillanatában.

3.3. A klasszifikációs modell pontossága

A betanított gépi tanulási modellek (*Random Forest* és *Gradient Boosting*) teljesítményét a csoportosított keresztvalidáció során értékeltem a YOLO (17 kulcspont), a MediaPipe (33 kulcspont), valamint a hagyományos OptiTrack Mocap (130 egyedi dobás) által kinyert adathalmazokon. A hiperparaméter-hangolás után a videóalapú adathalmazok (YOLO és MediaPipe) esetében a legjobb modell átlagosan 65%-os átfogó prediktív pontosságot (accuracy) ért el a dobások eredményességének (bedobott vagy kihagyott) előrejelzésében. Ezzel szemben a 3D marker-alapú OptiTrack Motive adatokon betanított *Random Forest* modell szignifikánsan jobban teljesített, elérve a **69,30%-os keresztvalidációs pontosságot**. Ez az eredmény bizonyítja, hogy a valós, nagy pontosságú térbeli 3D kinematikai adatok alkalmazása érezhetően növeli az algoritmus prediktív erejét a 2D videós alapvonalhoz (baseline) képest.

A modell változóinak fontossági elemzése (feature importance) rámutatott arra, hogy a MediaPipe adathalmaz esetében a legjelentősebb tényező a mutatóujj (*index finger*) mozgásdinamikája volt az elengedés körüli fázisban, míg a YOLO esetében a térdhajlítás kezdőfázisa dominált. A Mocap adatok esetében ugyanakkor a leginkább meghatározó tényezőknek a **váll és a könyök valós 3D-s szöge** (*shoulder angle* és *elbow x*) bizonyult közvetlenül a dobás tetőpontján. A komplex térbeli adatok használata tehát igazolta, hogy a felső végtagok valós 3D kinematikájának, illetve a finommotorikus elemek (például az ujjak mozgása) felismerése kiemelt fontosságú a sikeres predikcióban.



3.1. ábra. A gépi tanulási modell változóinak fontossági sorrendje (normalizált Feature Importance). A 3.1. ábra alapján látható a legmeghatározóbb tényezők rangsora.

4. fejezet

Diszkusszió és Összefoglalás

Jelen Tudományos Diákköri dolgozatban egy komplex, videóalapú biomechanikai elemző szoftverrendszert mutattam be, amellyel saját rögzítésű kosárlabda büntetődobások kinematikáját vizsgáltam marker nélküli pózbecslési technológiák (YOLO és MediaPipe) segítségével.

4.1. Az eredmények értékelése

A kapott eredmények megerősítik a korábbi irodalmi hivatkozások állításait [7, 11], miszerint a dobás sikeressége szorosan összefügg a biomechanikai konzisztenciával és a kinematikai lánc szinkronizációjával. A vizsgált sikeres dobások esetében a felső és alsó végtagok mozgását harmonikusabbnak találtam, míg a rontott kísérleteknél jelentősebb variabilitás mutatkozott.

A hagyományos 3D marker-alapú (OptiTrack) rendszer adataira betanított gépi tanulási modell által elért 69,30%-os pontosság szignifikánsan meghaladta a videóalapú rendszerek (YOLO és MediaPipe) 65%-os átlagát, és mindkét módszer messze felülmúlta a véletlenszerű 50%-os találati arányt. Ez egyrészt igazolja a valós 3D adatok fölényét a prediktív modellezésben, másrészt bizonyítja, hogy az algoritmus mindkét adatforrás esetén sikeresen megtalálta a hibás mozgásmintázatok és a rontott dobások közötti összefüggést. Ugyanakkor ez a mutató rámutat arra a tényre is, hogy csupán az alapvető ízületi szögek (makro-kinematika) elemzésével nem lehet 100%-os bizonyossággal megjósolni egy büntetődobás kimenetelét. A dobás pontosságát rendkívül apró, finommotorikus tényezők (például a labda perdülete, vagy az ujjak leválásának milliszekundumos időzítése) is befolyásolják, amelyeket sem a videóalapú számítógépes látásmód, sem a korlátozott felbontású Mocap nem képes minden esetben tökéletesen rögzíteni.

4.2. Limitációk és továbbfejlesztési lehetőségek

A kutatás legfőbb korlátját az egyetlen monokuláris kamera használata jelentette. Bár a MediaPipe képes a mélység (Z-tengely) becslésére is, a 2D-s videóképből történő 3D-s rekonstrukció torzításokat tartalmazhat. Ezt a limitációt a jövőben több, szinkronizált kameraállás (multi-view trianguláció) bevezetésével lehetne csökkenteni a térbeli pontosság maximalizálása érdekében.

További javasolt továbbfejlesztési lehetőség a szoftver hordozható mobilkörnyezetbe (okostelefonos alkalmazásba) történő integrálása. A marker nélküli pózbecslés egyik legnagyobb előnye, hogy nem igényel drága laboratóriumi körülményeket. Egy telefonos applikáció révén az edzők és a játékosok valós időben, közvetlenül a pálya szélén kaphatnának objektív visszacsatolást a dobástechnikájukról.

4.3. Konklúzió

Összegzésképpen elmondható, hogy a modern számítógépes látásmódra épülő algoritmusok alkalmasak az élsportolói mozgáselemzés támogatására. Bár a technológia még rendelkezik korlátokkal a mikromozgások elemzése terén, a kifejlesztett szoftverrel sikeresen bizonyítottam, hogy a gépi tanulás és a videóalapú pózbecslés ötvöztetésével értékes, automatizált sportanalitikai eszközök hozhatók létre, amelyek segíthetik a teljesítményfokozást.

Irodalomjegyzék

- [1] Miguel-Angel Gómez – Alberto Lorenzo – Jaime Sampaio – Sergio J Ibáñez – Enrique Ortega: Free throw shooting performance in basketball: An analysis of contextual variables. *International Journal of Performance Analysis in Sport*, 15. évf. (2015) 1. sz., 321–332. p. DOI: 10.21608/ajssa.2019.135378.
- [2] Jackie L Hudson: Prediction of basketball skill using biomechanical variables. *Research Quarterly for Exercise and Sport*, 56. évf. (1985) 2. sz., 115–121. p. DOI: 10.1080/02701367.1985.10608445.
- [3] Kien L Tran – Larry M Silverberg: Optimal release conditions for the free throw in men's basketball. *Journal of Sports Sciences*, 26. évf. (2008) 11. sz., 1147–1155. p. DOI: 10.1080/02640410802004948.
- [4] Stuart Miller – Roger Bartlett: The relationship between basketball shooting kinematics, distance and playing position. *Journal of Sports Sciences*, 14. évf. (1996) 3. sz., 243–253. p. DOI: 10.1080/02640419608727708.
- [5] Victor Hugo Alves Okazaki – André Luiz Félix Rodacki: Increased distance of shooting on basketball jump shot. *Journal of Sports Sciences*, 30. évf. (2012) 3. sz., 231–237. p. DOI: 10.5114/hm.2018.73615.
- [6] Bruce C Elliott: A kinematic comparison of the male and female two-point and three-point jump shots in basketball. *Australian Journal of Science and Medicine in Sport*, 24. évf. (1992) 4. sz., 111–117. p. DOI: 10.3390/ijerph18030934.
- [7] Chris Button – Mhairi MacLeod – Ross Sanders – Simon Coleman: Examining movement variability in the basketball free-throw action at different skill levels. *Research Quarterly for Exercise and Sport*, 74. évf. (2003) 3. sz., 257–269. p. DOI: 10.1080/02701367.2003.10609090.
- [8] David R Mullineaux – Tim L Uhl: Coordination-variability and kinematics of misses versus swishes of basketball free throws. *Journal of Sports Sciences*, 28. évf. (2010) 9. sz., 1017–1024. p. DOI: 10.1080/02640414.2010.487872.
- [9] Therese A Brisson – Claude Alain: Should common optimal movement patterns be identified as the criterion to be achieved? *Journal of Motor Behavior*, 28. évf. (1996) 3. sz., 211–223. p. DOI: 10.1080/00222895.1996.9941746.
- [10] A Penichet-Tomas – B Pueo – JM Jimenez-Olmedo: Biomechanical analysis of the jump shot in basketball. *Journal of Human Kinetics*, 62. évf. (2018), 23–31. p. DOI: 10.5114/biol sport.2020.95636.
- [11] MT Robins – JS Wheat – G Irwin – RM Bartlett: The effect of shooting distance on movement variability in basketball. *Journal of Human Movement Studies*, 50. évf. (2006) 4. sz., 217–238. p. DOI: 10.1080/14763140701322994.

- [12] K Verhoeven és mások: 3d tracking of basketball player kinematics using markerless motion capture. *Sports Engineering*, 24. évf. (2021) 1. sz., 12–22. p. DOI: 10.1007/springerreference_70824.
- [13] Liang Chen és mások: Application of computer vision in sports: A review. *IEEE Access*, 9. évf. (2021), 112345–112360. p. DOI: 10.3389/fspor.2025.1604232.
- [14] Zhe Cao – Tomas Simon – Shih-En Wei – Yaser Sheikh: Realtime multi-person 2d pose estimation using part affinity fields. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (konferenciaanyag). 2017, 7291–7299. p. DOI: 10.1109/cvpr.2017.143.
- [15] Noriaki Nakano – Takuya Sakura – Kento Ueda – Lota Omura – Asoha Kimura – Yosuke Iino – Senshi Fukashiro – Shinsuke Yoshioka: Evaluation of 3d markerless motion capture accuracy using open-pose with multiple video cameras. *Frontiers in Sports and Active Living*, 2. évf. (2020), 50. p. DOI: 10.1101/842492.
- [16] Camillo Lugaresi – Jiuqiang Tang – Hadon Nash – Chris McClanahan – Esha Uboweja – Michael Hays – Fan Zhang – Chuo-Ling MacGlashan – Thiago Baccash – Jonathan Halbitschka és mások: Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019. DOI: 10.1016/j.jobe.2023.108294.
- [17] K Koseki és mások: Basketball shooting analysis using mediapipe. In *Proceedings of the International Conference on Sports Engineering* (konferenciaanyag). 2023. DOI: 10.5040/9781350961074.
- [18] F Javier Rojas – Mar Cepero – Antonio Oña – M Gutierrez: Kinematic adjustments in the basketball jump shot against an opponent. *Ergonomics*, 43. évf. (2000) 10. sz., 1651–1660. p. DOI: 10.4324/9780203166635-11.
- [19] Raoul RD Oudejans – F J Karle – F C Bakker: Catching the basketball: How do skilled players coordinate their movements? *Journal of Sports Sciences*, 20. évf. (2002) 5. sz., 401–408. p. DOI: 10.7717/peerj.9803/fig-2.
- [20] C Agudo-Ortega és mások: Kinematic variables of the free throw and their relationship with effectiveness in basketball. *European Journal of Human Movement*, 33. évf. (2014), 100–114. p. DOI: 10.15308/sinteza-2024-352-357.