



BUDAPESTI MŰSZAKI ÉS GAZDASÁGTUDOMÁNYI EGYETEM
GAZDASÁG- ÉS TÁRSADALOMTUDOMÁNYI KAR
TESTNEVELÉSI KÖZPONT

VÁRI GERGŐ

TUDOMÁNYOS DIÁKKÖRI DOLGOZAT

Kosárlabda büntetődobás biomechanikai elemzése videó
alapján

Konzulens:

Weisz-Tiba Klára Julianna
testnevelő tanár

Ágoston Dorottya
PhD hallgató

Budapest, 2026.

Tartalomjegyzék

1. Bevezetés	1
1.1. Irodalomkutatás	1
1.2. Célkitűzések	2
2. Módszertan	4
2.1. Mérésben résztvevő személyek	4
2.2. Mérési protokoll	4
2.3. Mérési eszközök bemutatása	5
2.4. Adatfeldolgozás	5
2.5. Statisztikai elemzés és gépi tanulás	6
3. Eredmények	7
3.1. A szoftveres feldolgozás teljesítménye	7
3.2. A dobás fázisainak azonosítása	7
3.3. A klasszifikációs modell pontossága	8
4. Diskusszió és Összefoglalás	9
4.1. Az eredmények értékelése	9
4.2. Limitációk és továbbfejlesztési lehetőségek	10
4.3. Konklúzió	10
Irodalomjegyzék	11

1. fejezet

Bevezetés

A kosárlabda az egyik legnépszerűbb sportág világszerte, amelyben a büntetődobás kritikus szerepet játszik a mérkőzések végkimenetelében. Mivel a büntetődobás egy zavartalan, rögzített távolságból végrehajtott statikus mozdulatsor, a sikeres végrehajtást szinte kizárólag a játékos technikája és biomechanikai mozgásmintája határozza meg. A magas szintű teljesítmény eléréséhez elengedhetetlen a mozgás optimalizálása, a dobás konzisztenciájának javítása és a hibák azonosítása.

1.1. Irodalomkutatás


A kosárlabda büntetődobás kinematikai és biomechanikai sajátosságait a sporttudomány évtizedek óta vizsgálja [8]. A sikeres dobás egyik legfontosabb tényezője az optimális elengedési paraméterek (release conditions) megléte: az elengedési szög, az elengedési magasság és az elengedési sebesség [19]. Az irodalom egyetért abban, hogy a jobb találati arány eléréséhez a magasabb elengedési pont és a megfelelő belépési szög biztosítása szükséges [11, 1].

Továbbá a mozgás koordinációja és variabilitása is meghatározó. [3] és [17] kutatásai kimutatták, hogy a profi játékosok dobásai konzisztensebbek, és a felső és alsó végtagok harmonikus mozgásláncában (kinematikai lánc) kevesebb az eltérés a sikeres dobásoknál. A dobások kimenetelének összehasonlító elemzése rámutatott arra, hogy az ízületi szögek (térd, könyök, váll) dinamikája eltér a bedobott és a kihagyott helyzetekben [12].

A mozgáselemzés hagyományosan szenzorokkal vagy markerekkel felszerelt kamerarendszerekkel történt, melyek pontossága magas, de drágák és laboratóriumi környezethez kötöttek [20]. A számítógépes látásmód (computer vision) fejlődésével azonban a marker nélküli pózbecslés (pose estimation) forradalmasította a sportanalitikát [5].

Az olyan neurális hálózatok, mint az OpenPose [4] vagy a YOLO (You Only Look Once), képesek egy egyszerű videófelvételből is felismerni a játékosok testpontjait. A YOLO rendkívül gyors, de jellemzően csak 17 alapvető testpontot detektál.

A Google által fejlesztett MediaPipe keretrendszer [10] egy másik kiemelkedő megoldást nyújt, amely 33 térbeli (3D) referenciapontot (landmark) biztosít. Ez magában foglalja az ujjak, a kézfej és az arc finomabb pontjait is, ami sokkal részletesebb alapot ad a biomechanikai elemzésekhez. A legújabb kutatások már kifejezetten a MediaPipe-et használják kosárlabda dobáselemzésre [9].



1.1. ábra. A MediaPipe által detektált 33 térbeli landmark pontrendszere.

1.2. Célkitűzések

Jelen Tudományos Diákköri (TDK) munka célja egy olyan automatizált biomechanikai elemző szoftverrendszer kidolgozása, amely képes kosárlabda büntetődobások egyszerű videós felvételeiből kinematikai adatokat kinyerni marker nélküli pózbecslés segítségével. A kutatás során az alábbi célok kerültek megfogalmazásra:

- A dobás szempontjából kritikus paraméterek (könyök-, váll- és térdszögek, elengedési pont) folyamatos nyomon követése a mozgás során.

- Egy gépi tanulási (Machine Learning) klasszifikációs modell betanítása, amely kísérletet tesz a dobás kimenetelének (sikeres vagy sikertelen) előrejelzésére a kinyert adatok alapján.
- Annak vizsgálata, hogy a modern számítógépes látásmódon alapuló technológiák (YOLO és MediaPipe) miként integrálhatók egy automatizált, edzőket és játékosokat támogató sportanalitikai rendszerbe.

2. fejezet

Módszertan

2.1. Mérésben résztvevő személyek

A kutatás során 7 igazolt, versenyszerű kosárlabda múlttal rendelkező játékos (6 férfi, 1 nő) bevonásával történt az adatgyűjtés. A mérésben résztvevő összes személy jobbkezes volt. A férfi játékosok fizikai paraméterei és tapasztalati szintje részletesen rögzítésre került: átlagéletkoruk 20–21 év (2005–2006-os születésűek), átlagos testmagasságuk 185,8 cm (179–196 cm), míg átlagos testtömegük 82,2 kg (72–92 kg) volt. A játékosok mindannyian jelentős kosárlabda tapasztalattal rendelkeztek, átlagosan 12,7 év (11–14 év) igazolt sportmúlttal. Ezek a részletes fizikai és demográfiai adatok biztosították, hogy a gépi tanulási modell megfelelő és releváns variabilitású mintán kerüljön betanításra.

Nem	Születési év	Testmagasság (cm)	Testtömeg (kg)	Tapasztalat (év)
Nő	-	-	-	-
Férfi	2005	180	72	14
Férfi	2006	179	87	14
Férfi	2006	181	73	11
Férfi	2005	186	80	14
Férfi	2005	196	92	11
Férfi	2006	193	89	12

2.1. táblázat. A mérésben résztvevő játékosok fizikai és demográfiai adatai (valamennyi résztvevő jobbkezes volt).

2.2. Mérési protokoll

A videófelvételek készítése valós környezetben, szabványos kosárlabdapályán történt. A mérési folyamat során a játékosok büntetődobásokat hajtottak végre, miközben a mozgásukat egy fix pozícióban rögzített okostelefon kamerája rögzítette oldalnézetből.

A felvételek készítése során biztosítva lett, hogy a teljes test látható maradjon a dobás teljes időtartama alatt. A rögzített felvételeken feljegyzésre került minden egyes dobás kimenetele (sikeres vagy sikertelen találat), amely elengedhetetlen feltétele volt a későbbi felügyelt tanulásnak (supervised learning).


2.3. Mérési eszközök bemutatása

Az adatkinyerés során két különböző, marker nélküli pózbecslő szoftveres eszköz integrálására és vizsgálatára került sor:

- **YOLO (You Only Look Once):** Egy rendkívül gyors, grafikus kártyára (GPU) optimalizált algoritmus, amely 17 alapvető kétdimenziós (2D) ízületi pontot képes azonosítani.
- **MediaPipe:** A Google által fejlesztett rendszer, amely 33 darab háromdimenziós (3D) testpontot (köztük a kézfej pontjait) határoz meg. Bár futtatása hagyományos processzoron (CPU) történik és önmagában lassabb, a több referenciapont miatt részletesebb kinematikai elemzést tesz lehetővé.

A feldolgozás felgyorsítása érdekében a YOLO esetében TensorRT nevű technológia alkalmazására került sor, amely a grafikus kártya számítási kapacitását optimalizálja. A MediaPipe hátránya pedig a processzormagokon végzett párhuzamosított futtatással (parallelization) lett kompenzálva, így biztosítva a megfelelő feldolgozási sebességet.


2.4. Adatfeldolgozás



2.1. ábra. A biomechanikai adatfeldolgozás automatizált szoftveres folyamatábrája.

A nyers videófelvételek első lépésben automatikusan feldarabolásra kerültek, így a folyamatos videókból izolált, önálló dobási szekvenciák (klipek) jöttek létre. Ezen klipek minden egyes képkockáján azonosításra kerültek az ízületi pontok (landmarkok) a pózbecslő algoritmusok segítségével.

A felismert landmarkok alapján kiszámításra kerültek a vizsgált ízületi szögek (például a térdhajlítás és a könyöknyitás szöge). A dobás elengedési pontja (release point) a könyök magasságának maximális értékéhez lett rendelve. A rögzített adatok zajsűrése exponenciális mozgóátlag (EMA) segítségével történt, amely kisimította az esetleges mérési pontatlanságokat, és stabil kinematikai görbéket eredményezett.



2.2. ábra. A feldolgozó rendszer által készített vizualizáció, amely valós időben mutatja az azonosított ízületi pontokat és az aktuális hajlásszögeket.

2.5. Statisztikai elemzés és gépi tanulás

A kinyert kinematikai adatokból komplex idősoros változók (features) kerültek képzésre. A kulcsízületek (csukló, könyök, váll, csípő, térd) függőleges elmozdulása 30 egyenlő időlépésre (timestep) lett felosztva lineáris interpolációval. Ezen felül olyan statisztikai mutatók is számításra kerültek, mint a csukló mozgástartománya vagy a sebesség az elengedés pillanatában.

A predikcióhoz két együttes tanulási modell került betanításra: a *Random Forest* (Véletlen Erdő) és a *Gradient Boosting* (Gradiens Emelés). A modell megbízhatóságának tesztelésére egy 5-szörös keresztvalidációs (StratifiedGroupKFold) módszer alkalmazására került sor. Ennek az eljárásnak a lényege, hogy egy játékos azonos dobásai soha nem kerülhettek egyszerre a modell tanítására és tesztelésére használt adatok közé, elkerülve ezzel a torzított eredményeket (adatszivárgást).

3. fejezet

Eredmények

3.1. A szoftveres feldolgozás teljesítménye

A kifejlesztett rendszer sikeresen dolgozta fel az izolált videófelvevételeket. A YOLO algoritmus grafikus kártyán futtatott, hardveresen gyorsított verziója kiemelkedően magas képkocka/másodperc (FPS) feldolgozási sebességet biztosított. A MediaPipe ezzel szemben a 33 darab, térbeli mélységinformációval is rendelkező landmark miatt lassabbnak bizonyult, de a párhuzamosítási technikák révén a feldolgozás átbocsátóképessége a gyakorlatban is használható szintre emelkedett. Az exponenciális mozgóátlagos zajszűrés mindkét technológia esetében sikeresen eliminálta az ízületi pontok apró remegéseit (*jittering*).

A vizualizáció részeként legenerált áttetsző képernyőn (lásd 2.2. ábra) megfigyelhető volt, hogy az algoritmusok stabilan követik a játékosok mozgását, és az ebből számolt ízületi szögek (térd-, csípő- és könyökszög) megegyeznek a várt biomechanikai paraméterekkel.


3.2. A dobás fázisainak azonosítása

Az elengedési pont (release point) detektálására szolgáló algoritmus megbízhatóan azonosította a dobás tetőpontját. Az adatok alapján rögzítésre került a sikeres és sikertelen dobások kinematikai görbéje. Megállapítást nyert, hogy a sikeres dobásoknál a könyök- és térdszögek időbeli kinyílása szinkronban történik, és a görbék lefutása a játékosok több dobása esetén is szorosabb, konzisztensebb mintázatot mutat. Ezzel szemben a rontott kísérleteknél megnövekedett a mozgás variabilitása, és gyakran aszinkronitás volt megfigyelhető az alsó és felső végtagok mozgásláncában az elengedés pillanatában.

3.3. A klasszifikációs modell pontossága

A betanított gépi tanulási modellek (*Random Forest* és *Gradient Boosting*) teljesítménye a csoportosított keresztvalidáció során került értékelésre, mind a YOLO (17 testpont), mind a MediaPipe (33 testpont) által kinyert adathalmazokon. A hiperparaméter-hangolás után a legjobb modell mindkét adatbázis esetében azonos, 65%-os átfogó prediktív pontosságot (accuracy) ért el a dobások eredményességének (bedobott vagy kihagyott) előrejelzésében.

A modell változóinak fontossági elemzése (feature importance) rámutatott arra, hogy a MediaPipe adathalmaz esetében a legjelentősebb tényező a mutatóujj (*index finger*) mozgásdinamikája volt az elengedés körüli fázisban, míg a YOLO esetében a térdhajlítás kezdőfázisa dominált. A részletesebb hálózat használata tehát igazolta, hogy a finommotorikus elemek (például az ujjak mozgása) felismerése kiemelt fontosságú a predikcióban.



3.1. ábra. A gépi tanulási modell változóinak fontossági sorrendje (normalizált Feature Importance).

4. fejezet

Diszkusszió és Összefoglalás

Jelen Tudományos Diákköri dolgozatban egy komplex, videóalapú biomechanikai elemző szoftverrendszer került bemutatásra, amely saját rögzítésű kosárlabda büntetődobások kinematikáját vizsgálta marker nélküli pózbecslési technológiák (YOLO és MediaPipe) segítségével.

4.1. Az eredmények értékelése

A kapott eredmények megerősítik a korábbi irodalmi hivatkozások állításait [3, 17], miszerint a dobás sikeressége szorosan összefügg a biomechanikai konzisztenciával és a kinematikai lánc szinkronizációjával. A vizsgált sikeres dobások esetében a felső és alsó végtagok mozgása harmonikusabb volt, míg a rontott kísérleteknél jelentősebb variabilitás mutatkozott.

A kifejlesztett gépi tanulási modell által elért 65%-os pontosság szignifikánsan meghaladja a véletlenszerű 50%-os találati arányt, ami bizonyítja, hogy az algoritmus sikeresen megtalálta a hibás mozgásmintázatok és a rontott dobások közötti összefüggést. Ugyanakkor ez a mutató rámutat arra a tényre is, hogy csupán az alapvető ízületi szögek (makro-kinematika) elemzésével nem lehet 100%-os bizonyossággal megjósolni egy büntetődobás kimenetelét. A dobás pontosságát rendkívül apró, finommotorikus tényezők (például a labda perdülete, vagy az ujjak leválásának milliszekundumos időzítése) is befolyásolják, amelyeket az alkalmazott számítógépes látásmód egyetlen kameraállásból, a jelenlegi felbontás mellett csak korlátozottan képes érzékelni.

4.2. Limitációk és továbbfejlesztési lehetőségek

A kutatás legfőbb korlátját az egyetlen monokuláris kamera használata jelenti. Bár a MediaPipe képes a mélység (Z-tengely) becslésére is, a 2D-s videóképből történő 3D-s rekonstrukció torzításokat tartalmazhat. Ezt a limitációt a jövőben több, szinkronizált kameraállás (multi-view trianguláció) bevezetésével lehetne csökkenteni a térbeli pontosság maximalizálása érdekében.

További javasolt továbbfejlesztési lehetőség a szoftver hordozható mobilkörnyezetbe (okostelefonos alkalmazásba) történő integrálása. A marker nélküli pózbecslés egyik legnagyobb előnye, hogy nem igényel drága laboratóriumi körülményeket. Egy telefonos applikáció révén az edzők és a játékosok valós időben, közvetlenül a pálya szélén kaphatnának objektív visszacsatolást a dobástechnikájukról.

4.3. Konklúzió

Összegzésképpen elmondható, hogy a modern számítógépes látásmódra épülő algoritmusok alkalmasak az élsportolói mozgáselemzés támogatására. Bár a technológia még rendelkezik korlátokkal a mikromozgások elemzése terén, a kifejlesztett szoftver sikeresen bizonyította, hogy a gépi tanulás és a videóalapú pózbecslés ötvözésével értékes, automatizált sportanalitikai eszközök hozhatók létre, amelyek segíthetik a teljesítményfokozást.

Irodalomjegyzék

- [1] C Agudo-Ortega és mások: Kinematic variables of the free throw and their relationship with effectiveness in basketball. *European Journal of Human Movement*, 33. évf. (2014), 100–114. p.
- [2] Therese A Brisson – Claude Alain: Should common optimal movement patterns be identified as the criterion to be achieved? *Journal of Motor Behavior*, 28. évf. (1996) 3. sz., 211–223. p.
- [3] Chris Button – Mhairi MacLeod – Ross Sanders – Simon Coleman: Examining movement variability in the basketball free-throw action at different skill levels. *Research Quarterly for Exercise and Sport*, 74. évf. (2003) 3. sz., 257–269. p.
- [4] Zhe Cao – Tomas Simon – Shih-En Wei – Yaser Sheikh: Realtime multi-person 2d pose estimation using part affinity fields. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (konferenciaanyag). 2017, 7291–7299. p.
- [5] Liang Chen és mások: Application of computer vision in sports: A review. *IEEE Access*, 9. évf. (2021), 112345–112360. p.
- [6] Bruce C Elliott: A kinematic comparison of the male and female two-point and three-point jump shots in basketball. *Australian Journal of Science and Medicine in Sport*, 24. évf. (1992) 4. sz., 111–117. p.
- [7] Miguel-Angel Gómez – Alberto Lorenzo – Jaime Sampaio – Sergio J Ibáñez – Enrique Ortega: Free throw shooting performance in basketball: An analysis of contextual variables. *International Journal of Performance Analysis in Sport*, 15. évf. (2015) 1. sz., 321–332. p.
- [8] Jackie L Hudson: Prediction of basketball skill using biomechanical variables. *Research Quarterly for Exercise and Sport*, 56. évf. (1985) 2. sz., 115–121. p.
- [9] K Koseki és mások: Basketball shooting analysis using mediapipe. In *Proceedings of the International Conference on Sports Engineering* (konferenciaanyag). 2023.
- [10] Camillo Lugaresi – Jiuqiang Tang – Hadon Nash – Chris McClanahan – Esha Uboweja – Michael Hays – Fan Zhang – Chuo-Ling MacGlashan – Thiago Baccash – Jonathan Halbitschka és mások: Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019.
- [11] Stuart Miller – Roger Bartlett: The relationship between basketball shooting kinematics, distance and playing position. *Journal of Sports Sciences*, 14. évf. (1996) 3. sz., 243–253. p.
- [12] David R Mullineaux – Tim L Uhl: Coordination-variability and kinematics of misses versus swishes of basketball free throws. *Journal of Sports Sciences*, 28. évf. (2010) 9. sz., 1017–1024. p.

- [13] Noriaki Nakano – Takuya Sakura – Kento Ueda – Lota Omura – Asoha Kimura – Yosuke Iino – Senshi Fukushima – Shinsuke Yoshioka: Evaluation of 3d markerless motion capture accuracy using openpose with multiple video cameras. *Frontiers in Sports and Active Living*, 2. évf. (2020), 50. p.
- [14] Victor Hugo Alves Okazaki – André Luiz Félix Rodacki: Increased distance of shooting on basketball jump shot. *Journal of Sports Sciences*, 30. évf. (2012) 3. sz., 231–237. p.
- [15] Raoul RD Oudejans – F J Karle – F C Bakker: Catching the basketball: How do skilled players coordinate their movements? *Journal of Sports Sciences*, 20. évf. (2002) 5. sz., 401–408. p.
- [16] A Penichet-Tomas – B Pueo – JM Jimenez-Olmedo: Biomechanical analysis of the jump shot in basketball. *Journal of Human Kinetics*, 62. évf. (2018), 23–31. p.
- [17] MT Robins – JS Wheat – G Irwin – RM Bartlett: The effect of shooting distance on movement variability in basketball. *Journal of Human Movement Studies*, 50. évf. (2006) 4. sz., 217–238. p.
- [18] F Javier Rojas – Mar Cepero – Antonio Oña – M Gutierrez: Kinematic adjustments in the basketball jump shot against an opponent. *Ergonomics*, 43. évf. (2000) 10. sz., 1651–1660. p.
- [19] Kien L Tran – Larry M Silverberg: Optimal release conditions for the free throw in men's basketball. *Journal of Sports Sciences*, 26. évf. (2008) 11. sz., 1147–1155. p.
- [20] K Verhoeven és mások: 3d tracking of basketball player kinematics using markerless motion capture. *Sports Engineering*, 24. évf. (2021) 1. sz., 12–22. p.